PREVISÃO DE DEMANDA COM RANDOMFORESTREGRESSOR - TONELADAS TRANSPORTADAS EM FERROVIAS BRASILEIRAS

GUILHERME LIMA DE SOUSA – MBA DATA SCIENCE & ANALYTICS

Entre em contato comigo pelo Linkedin: www.linkedin.com/in/guilherme-lima-747355169

Introdução

Em 2019 tivemos um "boom" no transporte ferroviário de cargas, além dos inúmeros investimentos que foram anunciados para o setor. Com certeza um ano marcante para o modal, que em 2022 segundo o governo federal, (https://lnkd.in/di2ckPYm) participava de apenas 19% de toda a operação de transporte de cargas. Sendo estratégico para o escoamento de grandes quantidades, as ferrovias se mostram mais seguras e mais rápidas quando comparados ao modal rodoviário. Trazendo maior agilidade nas operações logísticas de transporte de cargas.

Objetivo

Este estudo almeja prever a quantidade de toneladas transportadas nas ferrovias Brasileiras em 2023, utilizando RandomForestRegressor da biblioteca scikit-learn no Python. Com dados de 2006 a 2022, coletados no site oficial da **ANTT – AGÊNCIA NACIONAL DE TRANSPORTES TERRESTRES** (https://dados.antt.gov.br/) e dados da **CNT – CONFEDERAÇÃO NACIONAL DO TRANSPORTE** (https://anuariodotransporte.cnt.org.br/2022/Ferroviario/2-7-2-/Aspectos-econ%C3%B4mico-financeiros) + (https://anuariodotransporte.cnt.org.br/2022/Ferroviario/2-2-1-/Estrutura-das-empresas).

Material e Métodos

Após a obtenção dos dados, foi realizado o tratamento (ETL) e unificação das bases.

Abaixo é observado as principais características do conjunto de dados:

	TU	MÊS	TONELADAS_MES_ANTERIOR	TONELADAS_ANO_ANTERIOR	QTD_EMPREGADOS	INVESTIMENTOS_MALHA
count	111131.00	111131.00	111131.00	111131.00	111131.00	103334.00
mean	72941.61	6.49	72186.99	64974.37	5413.69	418.18
std	462704.95	3.45	462123.82	436856.13	2814.16	374.81
min	1000.00	1.00	0.00	0.00	0.00	0.00
25%	3257.00	3.00	2832.00	568.00	4008.00	185.44
50%	8417.00	7.00	8034.00	5516.00	5548.00	339.58
75%	26274.00	9.00	25803.00	21011.00	7433.00	518.93
max	13858719.00	12.00	13858719.00	13858719.00	10272.00	4447.71

Depois é realizado a análise exploratória dos dados (EDA) com foco na coluna target, por meio de BOXPLOT:

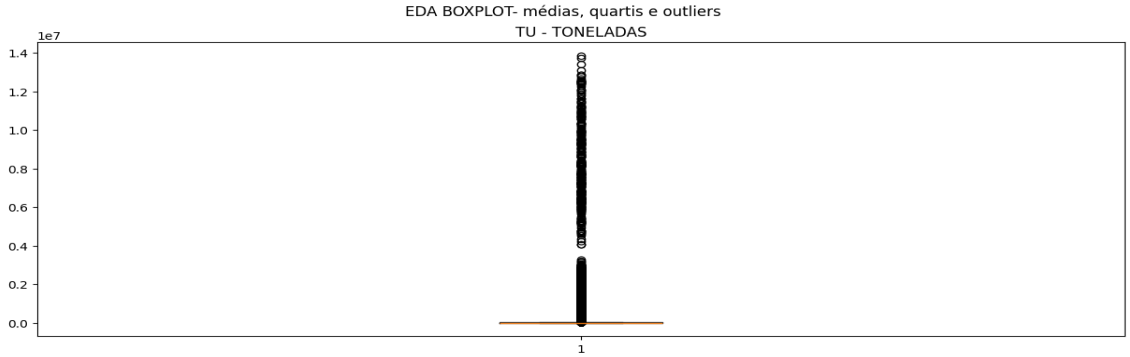

É verificado também quantos registros (contagem) possuem valor acima ou abaixo da média:

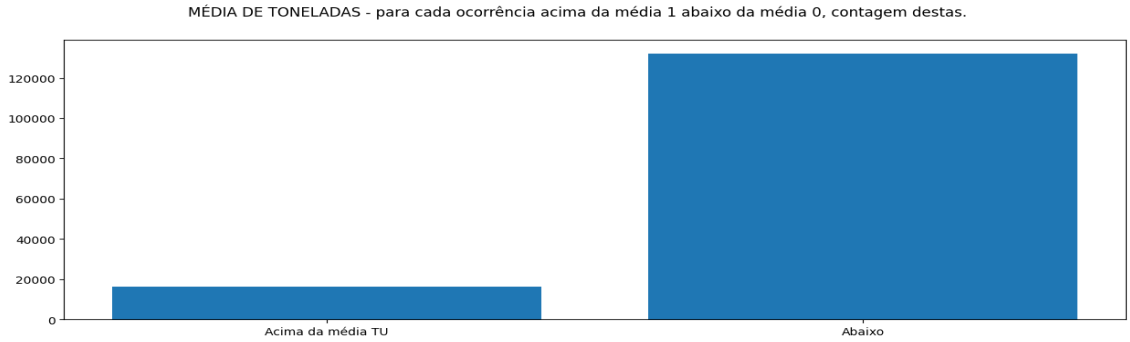

O que podemos observar até aqui é que nosso conjunto de dados está bastante diverso, isso é positivo, porém com muitos registros abaixo da média de toneladas e com outliers grandes.

Podemos observar a representatividade no volume de toneladas com foco na **UF de ORIGEM**:

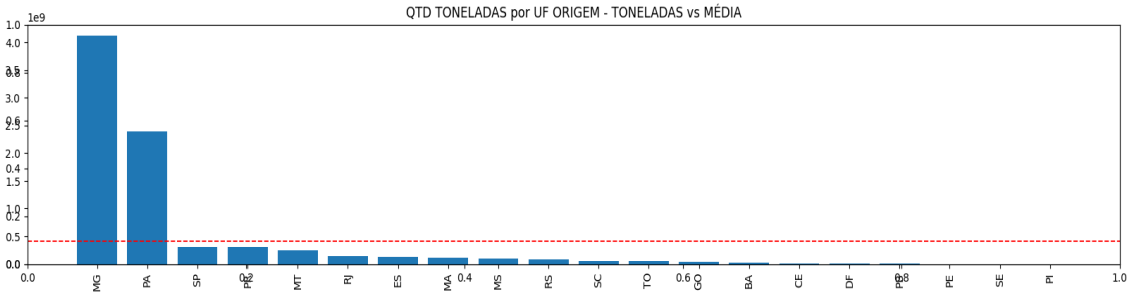

Podemos observar a representatividade no volume de toneladas com foco na **UF de DESTINO**:

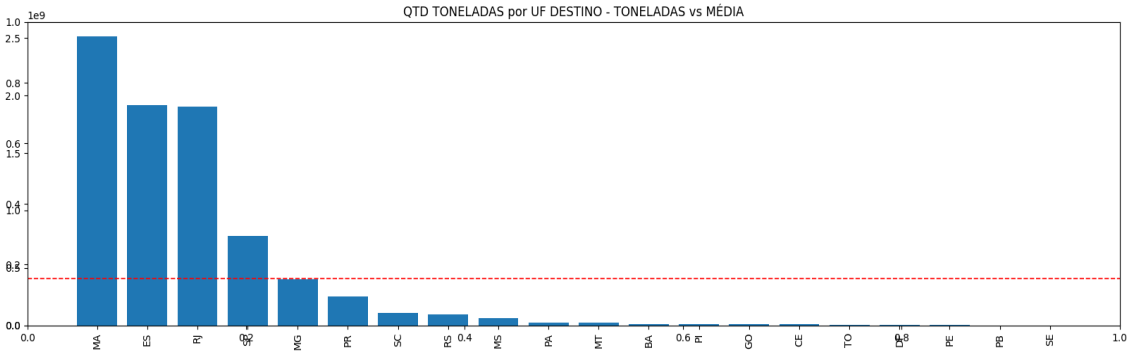

Os estados **MG, PA, SP** são os que mais enviam produtos pelas ferrovias e os estados **MA, ES, RJ** são os que mais recebem .... Com estes primeiros diagnósticos é possível compreender as características atuais do nosso conjunto de dados.

Foram realizadas transformações nas colunas de texto, aplicando códigos correspondentes a cada uma, pois o modelo só aceita colunas numéricas. Sendo assim, após as transformações, temos as colunas necessárias para compor o treinamento do modelo:

NOME_COLUNA	DESCRIÇÃO
MÊS	MÊS ATUAL
MES_SENO	SENO DO MÊS ATUAL
MES_COSSENO	COSSENO DO MÊS ATUAL
ANO	ANO ATUAL
COD_FERROVIA	CODIGO FERROVIA
COD_MERCADORIA_ANTT	CODIGO MERCADORIA
COD_ESTACAO_ORIGEM	CODIGO ESTACAO ORIGEM
COD_UF_ORIGEM	CODIGO UF ORIGEM
COD_ESTACAO_DESTINO	CODIGO ESTACAO DESTINO
COD_UF_DESTINO	CODIGO UF DESTINO
TU_LOG10	TONELADAS EM LOG10
TONELADAS_MES_ANTERIOR	TONELADAS DO MÊS ANTERIOR
TONELADAS_ANO_ANTERIOR	TONELADAS DO ANO ANTERIOR
MOM	MÊS VERSUS MÊS
QTD_EMPREGADOS	QUANTIDADE DE EMPREGADOS
INVESTIMENTOS_MALHA	VALORES ANUAIS INVESTIDOS NA MALHA

Como o nosso conjunto de dados é bastante complexo a sua distribuição não está muito próxima da normal e para ajustar essa distribuição, será feita uma transformação logarítmica de base 10 na coluna target (TU). Observe a distribuição dos dados **antes da transformação logarítmica**:

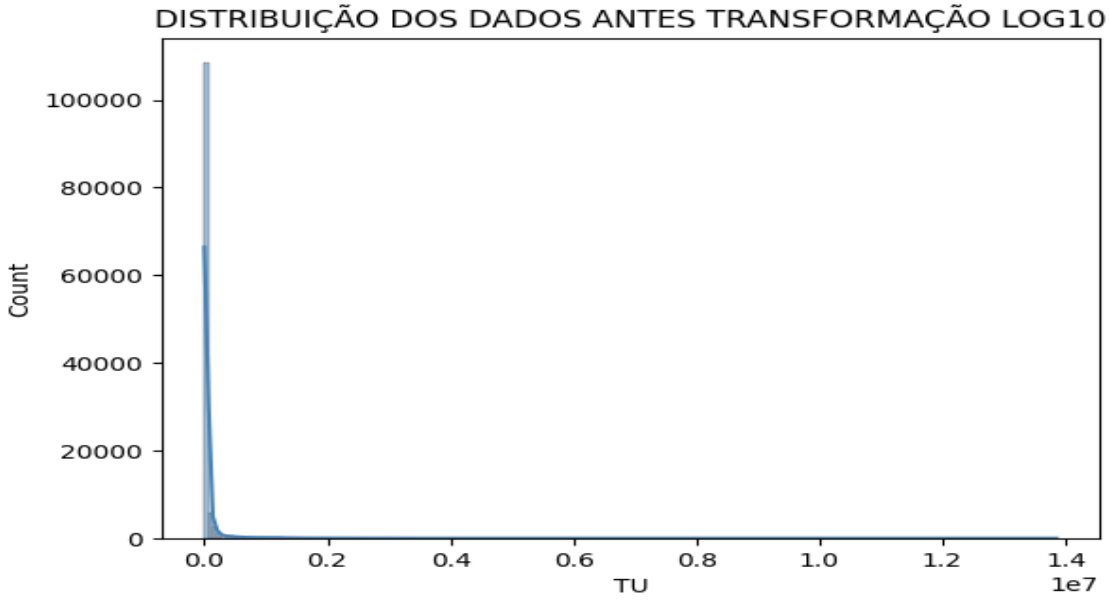

Observe a distribuição dos dados **após a transformação logarítmica**:

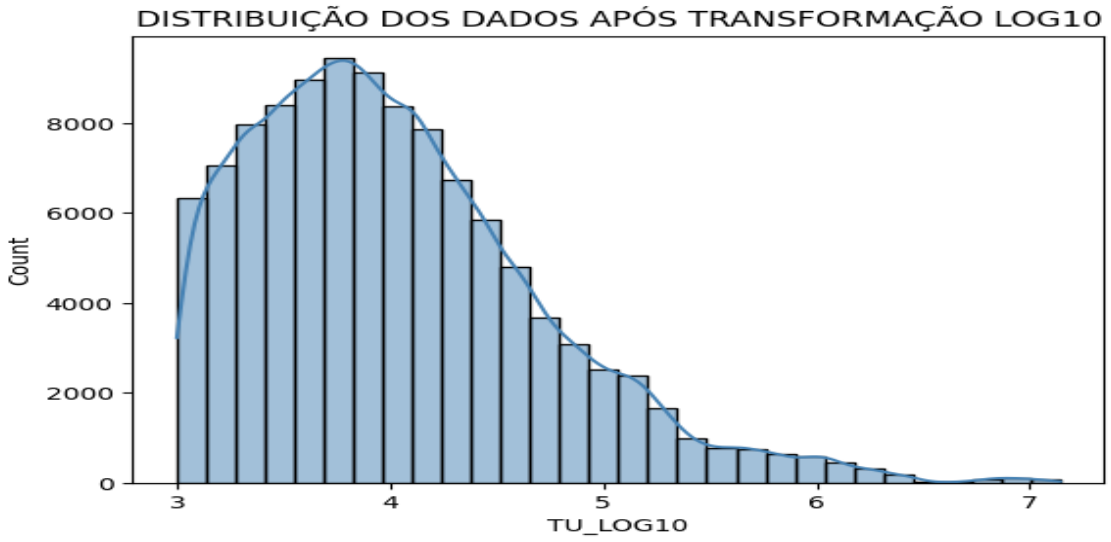

Treinando o Modelo

O modelo escolhido para predição dos valores foi o **RandomForestRegressor**, pois ele se adapta bem à conjuntos de dados complexos, como o nosso.

Na definição de parâmetros do modelo está sendo solicitado a criação de 10 árvores aleatórias, com profundidade máxima de 5 nós para cada árvore, e com reprodutibilidade ativado.

```
# CRIANDO MODELO (10 arvores, profundidade 5, replicabilidade seed 2)
modelo = RandomForestRegressor(n_estimators=10, max_depth=5, random_state=2)
```

Para assegurar ainda mais a performance do modelo, é definido o cross validation de 5 folds, sem embaralhamento dos dados, por meio do timeSeriesSplit:

```
# VALIDAÇÃO CRUZADA
#kf = KFold(n_splits=5, shuffle=True, random_state=2)
#cross_validation = cross_val_score(modelo, x, y, cv=kf, scoring='neg_mean_absolute_percentage_error', params={'sample_weight': (1 / (np.abs
from sklearn.model_selection import TimeSeriesSplit

# TIME SERIES SPLIT - CROSS VALIDATION
timeseries_cross_validation = TimeSeriesSplit(n_splits=5)

# EXECUTANDO A VALIDAÇÃO CRUZADA (sem embaralhamento shuffle=True)
cross_validation = cross_val_score(modelo, x_train, y_train, cv=timeseries_cross_validation, scoring='neg_mean_absolute_percentage_error')
```

Na validação cruzada o modelo é dividido em K-Folds (partes iguais) e avaliado em cada etapa. Quando não é utilizado o método de validação cruzada, o modelo fica enviesado apenas aquela única divisão dos dados, o que pode limitar a sua performance. Então a validação cruzada permite que o conjunto de dados seja dividido em pequenas partes, com cada subconjunto distinto e treinando o modelo em cada um deles, permitindo observar melhor o desempenho total.

Após o treinamento do modelo foi obtido um resultado de 0,85 ou 85% de assertividade (R2). O que é considerado um resultado bom para embasar decisões.

```
----------  RESULTADOS MODELO DUMMY  ----------
R²: -0.02282323461407887
MSE: 223363969536.86682
RMSE:  472613.97518150776
#######################################################

----------  RESULTADOS MODELO SIMPLES  ----------
O tipo do modelo carregado é: <class 'sklearn.ensemble._forest.RandomForestRegressor'>
Acuracia para cada fold (cross-validation): [-0.03330595 -0.02834923 -0.02862543 -0.02948927 -0.03022437]
Acuracia média (cross-validation): -2.9998851211018396
Desvio padrão (cross validation): 0.001780728505256801
R²: 0.95
MAE: 17968.158061748632
MSE (Mean squared error): 11035893478.885956
RMSE (Root Mean Squared Error): 105051.86090158497
MAPE: 27.28%
MedAE: 1782.15
```

O que podemos fazer para melhorar o resultado do modelo?

Dentre as possibilidades que podemos empregar para melhorar o resultado deste modelo será utilizado o processo de **AUTO TUNNING** através do RandomizedSearchCV, que é uma classe dentro do scikit-learn para encontrar automaticamente os melhores hiperparâmetros para um modelo. Ele sorteia combinações aleatórias de hiperparâmetros dentro de intervalos que nós definimos e verifica qual combinação é melhor.

```
# Espaço de busca dos hiperparâmetros
param_dist = {
    'n_estimators': randint(100, 300),
    'max_depth': randint(1, 15),
    'min_samples_split': randint(1, 10),
    'min_samples_leaf': randint(1, 5),
    'max_features': ['auto', 'sqrt', 'log2'],
    'bootstrap': [True, False]
}

# Randomized Search
random_search = RandomizedSearchCV(
    estimator=rf,
    param_distributions=param_dist,
    n_iter=50,                  # número de combinações aleatórias testadas
    cv=5,                       # validação cruzada
    scoring='r2',               # métrica
    verbose=2,
    random_state=42,
    n_jobs=-1
)
```

Após a realização do AUTO TUNNING os parâmetros indicados que melhoram a performance são atribuídos ao modelo:

```
########### Melhores hiperparâmetros:
{'bootstrap': False, 'max_depth': 20, 'max_features': 0.8, 'min_samples_leaf': 3, 'min_samples_split': 17, 'n_estimators': 152}
########### Melhor Score encontrado:
```

e com isso nosso resultado sobe para 0.85 ou 85% de assertividade (R2). Um resultado melhor do que o inicial:

```
----------  RESULTADOS MODELO DUMMY  ----------
R²: -0.022823234614078 87
MSE: 223363969536.86682
RMSE:  472613.97518150776
#####################################################

----------  RESULTADOS MODELO AUTO TUNNING  ----------
O tipo do modelo carregado é: <class 'sklearn.ensemble._forest.RandomForestRegressor'>
Desvio padrão (cross validation): 0.0027495636462080003
MAE médio (cross-validation): 0.0373
R²: 0.92
MAE: 32283.429281153636
MSE (Mean squared error): 60155960753.338
RMSE (Root Mean Squared Error): 245267.1212236528
MAPE: 37.07%
MedAE: 1861.44
```

Posteriormente o modelo é salvo no diretório para podermos utilizar no estudo de caso.

Avaliando o Modelo

Para um modelo ser considerado realmente bom, outras métricas além da assertividade (R2) precisam ser avaliadas. Abaixo temos as avaliações destas outras métricas.

CURVA DE APRENDIZADO A curva de aprendizado mostra a capacidade de generalização do modelo ao comparar o desempenho entre os dados de treino e validação. Observa-se que, à medida que o volume de dados aumenta, tanto o R^2 de treino quanto o de validação crescem, indicando que o modelo está aprendendo de forma consistente. Nota-se um leve gap entre as curvas, com o desempenho em treino superior ao de validação, o que sugere um pequeno nível de overfitting, porém dentro de um limite aceitável. Além disso, a curva de validação começa a apresentar ganhos marginais com o aumento dos dados, indicando uma tendência de estabilização.

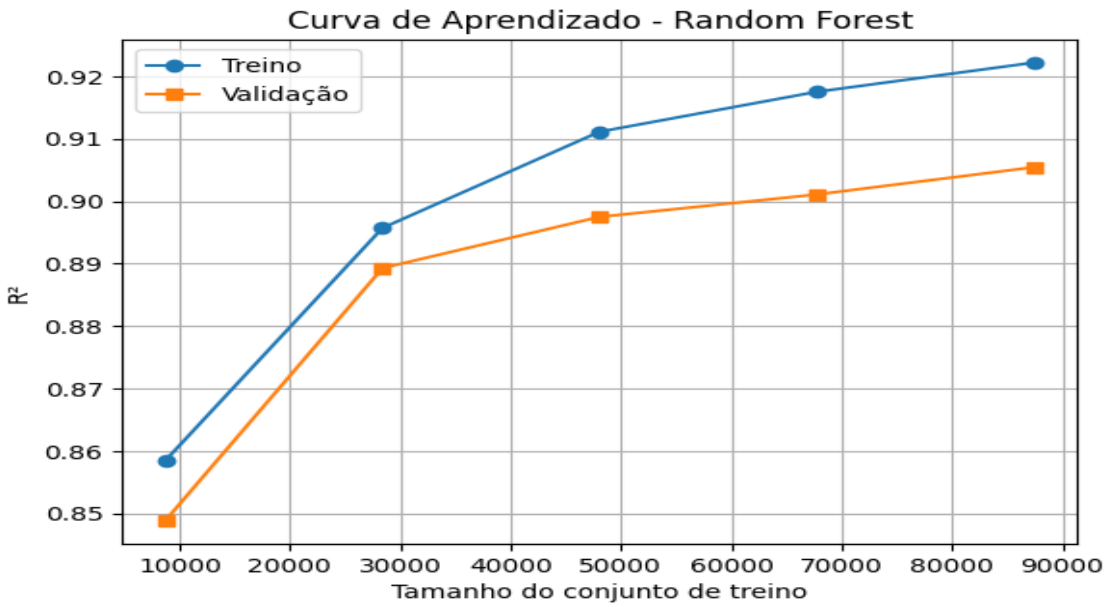

FEATURE IMPORTANCE A análise de feature importance mostra uma forte concentração de importância nas variáveis relacionadas ao histórico de volume, com destaque para TONELADAS_MES_ANTERIOR e TONELADAS_ANO_ANTERIOR, que juntas representam a maior parte da capacidade preditiva do modelo. As demais variáveis apresentam contribuição marginal, sugerindo que o modelo depende fortemente de padrões temporais recentes. Esse comportamento é esperado em problemas com componente temporal, porém indica uma possível limitação na capacidade de capturar outros fatores explicativos. Dessa forma, melhorias futuras podem estar associadas à criação de novas variáveis derivadas (feature engineering), especialmente relacionadas a tendência, sazonalidade e transformações das variáveis categóricas.

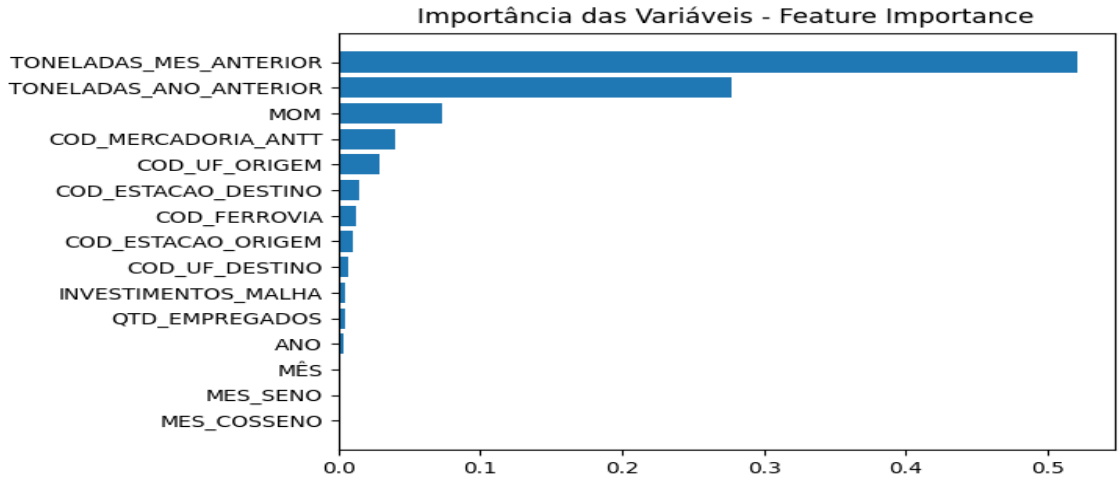

SHAP é uma técnica que verifica a contribuição individual de cada variável para a predição de um modelo. Ele responde à pergunta: "Quanto cada feature influenciou para aumentar ou diminuir o valor previsto?" ..... Na imagem podemos observar que a coluna TONELADAS_MES_ANTERIOR influencia muito para uma predição de valores altos, tendo uma concentração de bolinhas acima de zero.

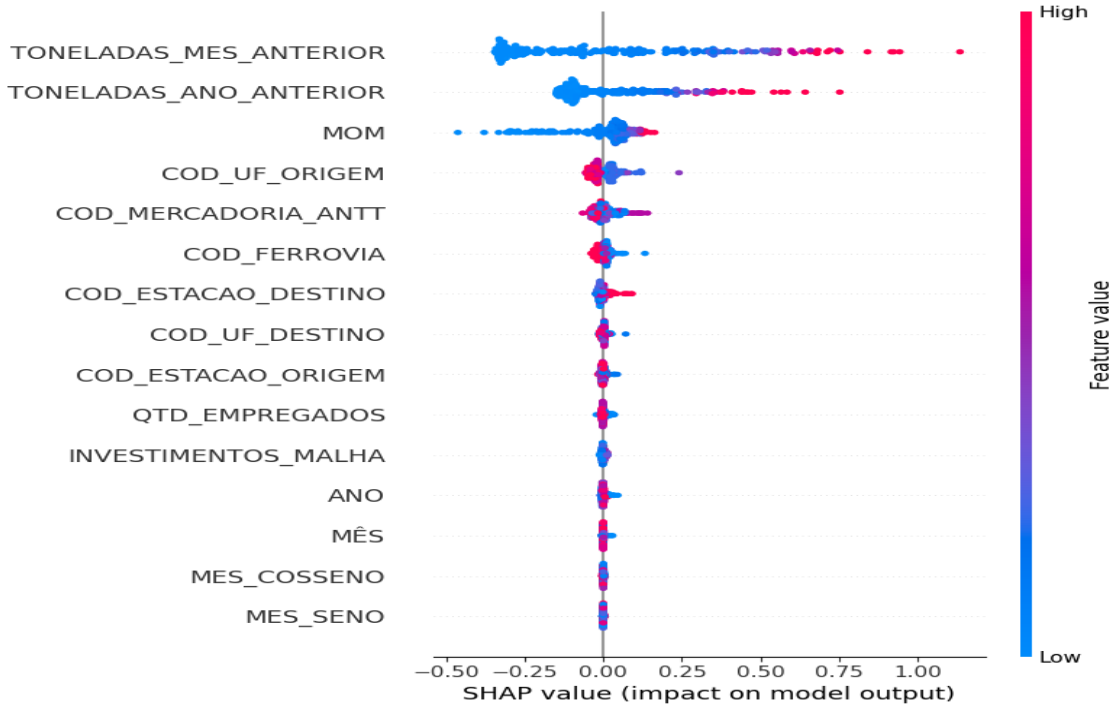

KOLMOGOROV SMIRNOV é um teste para comparar as distribuições do conjunto de treino e teste (apenas as features). Será que ao longo do meu ETL ou com recebimento de novos registros, a distribuição dos meus dados mudou? Se p < 0,05 → Há evidência de mudança significativa (COM drift / Distribuição alterada) ..... se p ≥ 0,05 → Não há evidência de mudança significativa (SEM drift / Distribuição mantida).

O nosso resultado de kolmogorov para as features mostra que apenas a coluna **MOM** *(p_value=0.06)* não sofreu drift, mas todas as outras sofreram drift em suas distribuições. Esse comportamento é esperado em validações com TimeSeriesSplit, já que comparamos diferentes janelas temporais, mas ainda assim representa um risco relevante para uso em produção.

```
################# KOLMOGOROV SMIRNOV #################
MÊS: KS_stat=0.0837, p_value=0.000000
MES_SENO: KS_stat=0.0685, p_value=0.000000
MES_COSSENO: KS_stat=0.0555, p_value=0.000000
ANO: KS_stat=0.9895, p_value=0.000000
COD_FERROVIA: KS_stat=0.0943, p_value=0.000000
COD_MERCADORIA_ANTT: KS_stat=0.0383, p_value=0.000000
COD_ESTACAO_ORIGEM: KS_stat=0.0372, p_value=0.000000
COD_UF_ORIGEM: KS_stat=0.0421, p_value=0.000000
COD_ESTACAO_DESTINO: KS_stat=0.0380, p_value=0.000000
COD_UF_DESTINO: KS_stat=0.0365, p_value=0.000000
TONELADAS_MES_ANTERIOR: KS_stat=0.0734, p_value=0.000000
TONELADAS_ANO_ANTERIOR: KS_stat=0.1276, p_value=0.000000
MOM: KS_stat=0.0133, p_value=0.061694
QTD_EMPREGADOS: KS_stat=0.5413, p_value=0.000000
INVESTIMENTOS_MALHA: KS_stat=nan, p_value=nan
#####################################
```

ANÁLISE DOS RESIDUOS um resíduo é a diferença entre o valor real e o valor que o modelo previu. Na imagem abaixo o gráfico demonstra HETEROCEDASTICIDADE pois os resíduos estão espalhados pelo gráfico, parecendo um funil ou tempestade. Isso significa que o modelo erra mais para algumas classes do que em outras, os riscos de usar um modelo que erra forte uma determinada classe é algo delicado a se pensar.

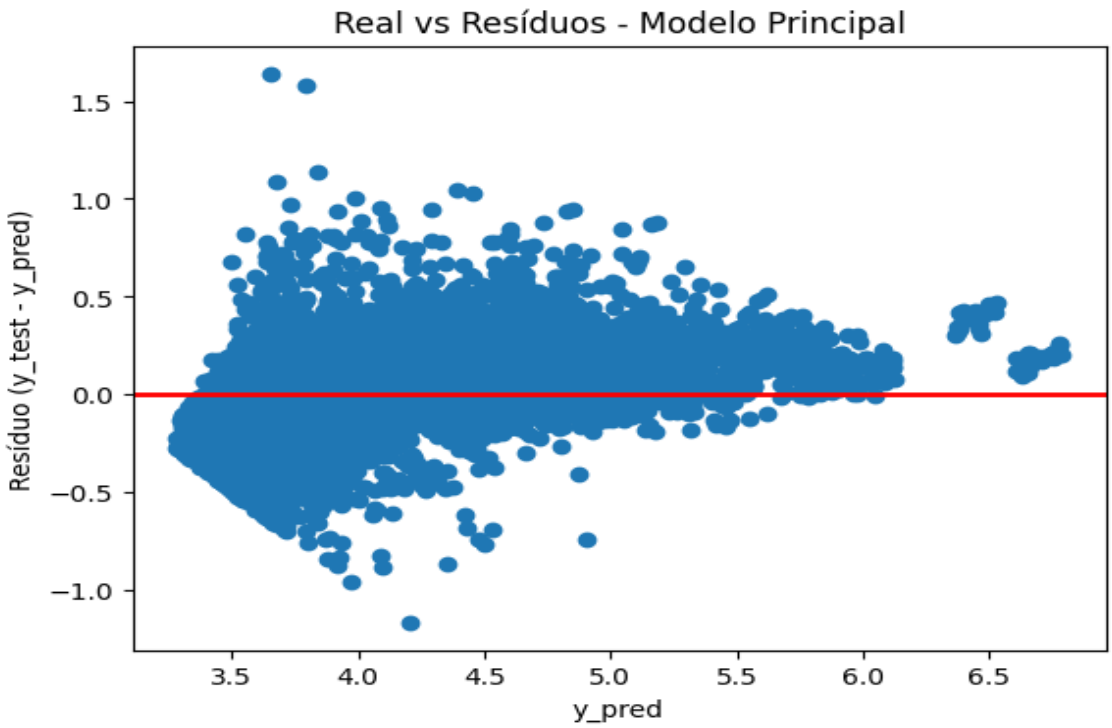

Como os outros resultados do modelo se mostraram favoráveis, uma solução para contornar essa heterocedasticidade seria criar um novo modelo refinado, usando apenas os erros do primeiro modelo, assim ele atuaria corretivamente nas instancias com erros grandes. Porém neste estudo de caso não abordaremos a criação de um novo modelo refinado, pois já utilizamos o RandomizedSearchCV ***(AUTOTUNNING).***

Cenário Fictício 2023 - aplicando o modelo

O modelo que foi treinado utilizando informações de 2006 até 2022 tem agora a missão de prever os valores de 2023. Após realizado as transformações necessárias (ETL) é preciso enquadrar o conjunto de dados com a mesma estrutura/ordem de colunas em que o modelo principal foi treinado.

Após aplicado, os resultados do modelo ao cenário de 2023 são observados na imagem abaixo:

```
----------  RESULTADOS CENARIO 2023  ----------
O tipo do modelo carregado é: <class 'sklearn.ensemble._forest.RandomForestRegressor'>
R² no conjunto de teste: 0.90
MAE: 36798.34168927582
RMSE: 239835.28374073777
MAPE: 40.65%
MedAE: 1918.50
```

O modelo consegue explicar cerca de 90% da variável alvo (TU - toneladas) e isso é melhor do que um chute aleatório, conta com um MAPE de 40%, o que significa que quando ele erra o modelo erra 58% a mais ou menos do valor real.

Cenário fictício regional recebedor - aplicando o modelo

O modelo que foi treinado utilizando informações de 2006 até 2022 tem agora a missão de prever os valores de (ES, MA, RJ). Após realizado as transformações necessárias (ETL) é preciso enquadrar o conjunto de dados com a mesma estrutura/ordem de colunas em que o modelo principal foi treinado.

Após aplicado, os resultados do modelo ao cenário são observados na imagem abaixo:

```
----------  RESULTADOS REGIONAL RECEBEDOR ----------
O tipo do modelo carregado é: <class 'sklearn.ensemble._forest.RandomForestRegressor'>
R² no conjunto de teste: 0.94
MAE: 76971.95541973572
RMSE: 437691.13316408347
MAPE: 36.32%
MedAE: 3118.10
```

O modelo consegue explicar cerca de 94% da variável alvo (TU - toneladas) e isso é melhor do que um chute aleatório, conta com um MAPE de 36%, o que significa que quando ele erra o modelo erra 36% a mais ou menos do valor real.

Cenário fictício regional envios - aplicando o modelo

O modelo que foi treinado utilizando informações de 2006 até 2022 tem agora a missão de prever os valores de (MG, PA, SP). Após realizado as transformações necessárias (ETL) é preciso enquadrar o conjunto de dados com a mesma estrutura/ordem de colunas em que o modelo principal foi treinado.

Após aplicado, os resultados do modelo ao cenário são observados na imagem abaixo:

```
----------  RESULTADOS REGIONAL ENVIOS ----------
O tipo do modelo carregado é: <class 'sklearn.ensemble._forest.RandomForestRegressor'>
R² no conjunto de teste: 0.93
MAE: 40462.874884245946
RMSE: 308625.0033036454
MAPE: 34.90%
MedAE: 1817.65
```

O modelo consegue explicar cerca de 93% da variável alvo (TU - toneladas) e isso é melhor do que um chute aleatório, conta com um MAPE de 34%, o que significa que quando ele erra o modelo erra 34% a mais ou menos do valor real.

Conclusão

Neste projeto, eu desenvolvi um modelo de regressão utilizando Random Forest com o objetivo de prever a demanda de transporte em toneladas. Começando pela performance, o modelo apresentou um R^2 em torno de 0.92 em validação cruzada, o que indica uma boa capacidade de capturar a variabilidade dos dados. Porém, quando olhamos para métricas de erro, o MAPE ficou próximo de 37%, o que é relativamente alto — ou seja, em média, as previsões podem variar cerca de 37% para cima ou para baixo em relação ao valor real. Isso já levanta um ponto importante: apesar do modelo explicar bem os dados, ele ainda não é suficientemente preciso para um ambiente produtivo sensível a erro financeiro.

Analisando a curva de aprendizado, observei um leve overfitting, mas controlado — a diferença entre treino e validação é pequena. Isso indica que o modelo generaliza razoavelmente bem dentro do padrão dos dados disponíveis. Um ponto que me chamou atenção foi a instabilidade do erro ao longo do tempo. Em alguns períodos, o MAPE chega a ultrapassar 45%, o que sugere que o modelo não está capturando totalmente efeitos temporais ou possíveis mudanças de comportamento dos dados. Quando analisei a importância das variáveis com SHAP, ficou claro que o modelo depende fortemente de dados históricos, como toneladas do mês e do ano anterior. Isso faz sentido do ponto de vista de negócio, mas também indica uma limitação: o modelo pode ter dificuldade em cenários de mudança brusca, como crises ou mudanças operacionais.

Além disso, apliquei o teste de Kolmogorov-Smirnov e identifiquei diferenças significativas entre as distribuições de treino e validação, indicando data drift, porém esse comportamento é esperado em validações com TimeSeriesSplit, já que estamos comparando diferentes janelas temporais, mas ainda assim representa um risco relevante para produção, pois indica mudança no padrão dos dados ao longo do tempo. Em contrapartida, quando analisei recortes específicos — como regiões com maior volume de envio ou recebimento — o modelo apresentou melhora no erro, sugerindo que uma abordagem segmentada pode ser mais eficiente do que um modelo global.

Por fim, comparando com um modelo baseline dummy, o Random Forest teve um ganho significativo, mostrando que de fato captura padrões relevantes dos dados.